

Extração Estruturada e Validação Contábil de Balanços Patrimoniais com Modelos de Linguagem

Estácio Cerqueira Lima

Programa de Pós-graduação em Estatística e Ciências de Dados da Universidade Federal da Bahia

Disciplina de Large Language Models

Brasil

estaciocerqueira7@gmail.com

6 de julho de 2026

Resumo

Documentos contábeis em PDF concentram informações essenciais para análise financeira de empresas, especialmente em rotinas de fundos de investimento que precisam avaliar balanços de cedentes, sacados, fornecedores ou potenciais investidas. Ainda assim, a extração manual desses dados é lenta, repetitiva e sujeita a erro, pois os balanços apresentam layouts, nomenclaturas, hierarquias de contas e padrões numéricos variados. Este trabalho apresenta uma metodologia para extração estruturada de balanços patrimoniais brasileiros com modelos de linguagem de larga escala (LLMs), seguida por uma camada determinística de validação contábil. O método lê o PDF, extrai seu conteúdo textual, envia o conteúdo para uma LLM com saída estruturada em JSON conforme um schema pré-definido e valida os valores retornados por meio de regras contábeis reproduzíveis. A principal contribuição está na separação entre interpretação semântica, delegada ao modelo, e verificação numérica, executada por regras determinísticas. O sistema recalcula campos obtidos por soma de contas, preserva valores originais, produz valores validados quando a correção é inequívoca e verifica a identidade ativos menos passivos menos patrimônio líquido igual a zero. A entrega normal do método é um dashboard financeiro para o analista; para fins de validação deste artigo, esse dashboard é comparado a um gabarito manual de uma empresa real nos anos de 2023, 2024 e 2025. A comparação obteve 57 células corretas em 69 avaliadas, correspondendo a 82,6% de aderência ao gabarito. Os três balanços foram processados com o modelo gpt-5.4-mini, consumindo 87.820 tokens no total e custo estimado de US\$ 0,136112, ou R\$ 0,707784.

Palavras-chave: Large Language Models, extração de informação, balanço patrimonial, validação contábil

1 Introdução

A análise de documentos contábeis é recorrente em avaliação econômico-financeira, concessão de crédito, auditoria, monitoramento de risco e due diligence. Em fundos de investimento, essa etapa aparece de forma prática na leitura de balanços de empresas relacionadas à carteira, como cedentes, fornecedores, devedores ou potenciais investidas. A análise manual desses documentos consome tempo de analistas, dificulta a comparação entre empresas e períodos e cria risco de transcrição incorreta de valores. Entre os documentos utilizados nesse processo, o balanço patrimonial ocupa posição central por apresentar, em uma data específica, a composição dos ativos, passivos e patrimônio líquido de uma entidade. Apesar da relevância, a transformação de balanços em PDF em dados estruturados ainda é custosa: os arquivos apresentam layouts heterogêneos, múltiplas colunas, quebras de linha irregulares, valores no padrão brasileiro, tabelas pouco explícitas e nomenclaturas contábeis variadas.

Soluções baseadas em expressões regulares e templates fixos funcionam melhor quando o documento é padronizado. Essa premissa não se sustenta bem no cenário considerado neste trabalho, no qual balanços de

empresas diferentes podem ser emitidos por escritórios distintos, usar contas com nomes variados e organizar valores em formatos divergentes. Por isso, a abordagem proposta não tem como foco a construção de regras de extração por regex, mas sim o uso de LLMs com output estruturado. Modelos de linguagem de larga escala oferecem uma alternativa interessante porque conseguem reconhecer equivalências semânticas entre expressões como “Ativo Total”, “Total do Ativo” e “Soma do Ativo”, além de mapear trechos textuais para schemas definidos. A literatura recente de modelos Transformer e LLMs mostrou ganhos expressivos em tarefas de compreensão textual e geração condicionada [1, 2, 3].

Entretanto, usar uma LLM para gerar um JSON não resolve sozinho o problema da confiabilidade. O modelo pode produzir uma estrutura sintaticamente válida, mas semanticamente incorreta: valores podem ser associados à conta errada, campos podem ser omitidos e cálculos podem ser executados de forma imprecisa. Esse risco é especialmente sensível em documentos financeiros, nos quais diferenças pequenas podem alterar indicadores e decisões posteriores. Assim, este trabalho parte da hipótese de que a extração com LLMs deve ser complementada por validações de domínio, preservação de evidências e auditoria.

O objetivo deste trabalho é apresentar e avaliar tecnicamente um pipeline para extração estruturada de balanços patrimoniais em PDF utilizando LLMs, com validação algorítmica de consistência contábil. O projeto busca apoiar a substituição de uma rotina manual de análise preliminar em fundos de investimento por um processo em que os valores extraídos sejam padronizados, comparáveis e auditáveis. O método recebe documentos, extrai texto, solicita à LLM uma saída aderente a um schema JSON, persiste o resultado bruto e executa uma etapa determinística que recalcula somas de contas e verifica a identidade fundamental:

$$ativos - passivos - patrimonio liquido = 0. \quad (1)$$

A contribuição principal é uma arquitetura híbrida: a LLM atua na leitura semântica e no mapeamento de campos, enquanto regras contábeis implementadas em Python executam cálculos, correções inequívocas, classificação de achados e registro de auditoria.

2 Trabalhos Relacionados

A extração de informação busca identificar e estruturar dados relevantes a partir de fontes não estruturadas ou semiestruturadas. Em documentos financeiros, a tarefa envolve tabelas, hierarquias, múltiplos períodos e raciocínio numérico. Modelos baseados em Transformer [1] e LLMs [2, 3] ampliaram a capacidade de interpretar textos variados, mas não eliminaram limitações ligadas à precisão factual e numérica.

Na área de Document AI, modelos como LayoutLM incorporam informações de layout para lidar com documentos visualmente estruturados [4]. Essa linha é relevante porque PDFs financeiros raramente são apenas texto linear: a posição espacial de rótulos e valores importa. Trabalhos recentes também discutem a dificuldade de avaliar extrações de tabelas em PDF e a utilidade de avaliação semântica assistida por LLMs [5]. No presente projeto, a etapa de leitura do PDF é tratada como preparação do conteúdo de entrada para a LLM, enquanto a contribuição central está na extração estruturada e na validação dos valores contábeis produzidos.

Saídas estruturadas em JSON são importantes para integrar LLMs a sistemas transacionais. Elas reduzem ambiguidades de formato e facilitam persistência, validação e consumo por dashboards. Porém, a conformidade ao schema é apenas uma condição formal. Em domínios como contabilidade, é necessário verificar se os valores respeitam relações internas. Essa preocupação aparece em benchmarks recentes de extração estruturada [6, 7] e se aproxima de abordagens de geração guiada por gramáticas ou schemas [8], nas quais a forma da saída é controlada, mas a verificação semântica continua sendo responsabilidade da aplicação.

Também há relação com arquiteturas que combinam LLMs e ferramentas auxiliares. Estudos sobre documentos fiscais e financeiros destacam que relações hierárquicas, agentes críticos e componentes calculadores podem melhorar a confiabilidade de pipelines baseados em LLMs [9, 10, 11]. Em vez de pedir que o modelo interprete, calcule, critique e audite a própria resposta, este projeto separa responsabilidades: o modelo extrai e classifica; o código determinístico calcula e valida; a aplicação persiste, exhibe e audita. Essa separação é adequada para documentos contábeis porque cálculos como somatórios e reconciliações devem ser reproduzíveis.

3 Metodologia

3.1 Visão Geral do Método

A metodologia proposta é organizada em quatro etapas: leitura do PDF, extração estruturada via LLM, validação determinística dos valores e comparação analítica dos resultados. A implementação computacional serve como prova de conceito desse fluxo, mas a contribuição do trabalho não está na tecnologia de interface utilizada. O ponto central é avaliar se uma LLM, orientada por output estruturado, pode transformar um balanço patrimonial heterogêneo em campos padronizados e se regras contábeis determinísticas podem aumentar a confiabilidade dessa saída.

O fluxo aplicado é composto pelas seguintes etapas:

1. o balanço patrimonial em PDF é lido e convertido para uma representação textual;
2. o texto extraído é enviado a uma LLM com instruções de extração e schema de output estruturado;
3. a LLM retorna um JSON contendo metadados, campos contábeis, contas de origem, fórmulas, alertas e indicadores de confiança;
4. o JSON original é preservado como saída bruta da extração;
5. regras determinísticas recalculam campos derivados e verificam relações contábeis fundamentais;
6. os valores extraídos e validados são apresentados em dashboard para análise; neste artigo, adicionalmente, o dashboard de uma empresa é comparado a um gabarito de referência.

Essa organização reflete o uso pretendido em fundos de investimento: substituir a leitura manual inicial do balanço por uma tabela estruturada que permita comparação rápida entre empresas e períodos. O analista deixa de transcrever manualmente os valores e passa a revisar divergências, campos ausentes e alertas produzidos pelo pipeline.

3.2 Leitura do PDF e Preparação do Texto

A entrada do método é um arquivo PDF de balanço patrimonial. Quando o PDF possui texto pesquisável, o conteúdo é extraído diretamente; quando necessário, pode ser aplicado OCR como etapa anterior. O resultado dessa fase não é tratado como uma tabela definitiva, mas como material textual de entrada para a LLM. Essa decisão é importante porque a variabilidade de layouts torna frágil depender exclusivamente de regex ou de posições fixas de colunas.

O texto enviado ao modelo preserva, sempre que possível, separações por página e indícios de estrutura tabular. A tarefa da LLM é interpretar esse conteúdo e preencher um schema comum, mesmo quando o documento utiliza nomenclaturas diferentes para contas equivalentes.

3.3 Extração com Output Estruturado

A chamada à LLM utiliza output estruturado: a resposta deve obedecer a um schema JSON estrito para representar metadados, campos de análise, conferência, contas não utilizadas e alertas. O uso de output estruturado é parte essencial da metodologia, pois reduz a necessidade de pós-processamento textual e permite que a saída seja diretamente validada, comparada e exibida em formato analítico.

O schema inclui informações como tipo de documento, razão social, CNPJ, período, moeda e escala dos valores. Em `campos_analise`, são solicitados grupos e indicadores relevantes para análise financeira, incluindo patrimônio líquido, ativo circulante, realizável a longo prazo, permanente, passivo circulante, exigível a longo prazo, total do balanço, prazo médio de recebimentos, liquidez corrente, liquidez seca e liquidez geral.

Cada item extraído contém valor, tipo de obtenção, fórmula, contas de origem, valor extraído diretamente, valor calculado, diferença entre cálculo e extração, confiança e observações. Essa modelagem força o modelo a explicitar quando um campo foi extraído diretamente, calculado por soma de contas, calculado como índice, não encontrado, não calculável ou ambíguo. Também permite que a etapa posterior audite quais contas sustentam cada valor.

O prompt restringe o modelo a usar apenas informações presentes no documento, não inventar valores, converter números brasileiros para formato numérico JSON, indicar contas de origem e registrar alertas quando houver ambiguidade. Assim, a LLM é utilizada para interpretação semântica e classificação contábil, não como fonte final de verdade numérica.

O modelo utilizado nos experimentos foi o `gpt-5.4-mini`. A escolha se justifica pelo perfil de custo-benefício: o objetivo não era maximizar desempenho com o modelo mais caro disponível, mas verificar se um modelo econômico seria suficiente para produzir uma extração estruturada útil, sujeita a validação determinística posterior.

3.4 Validação Contábil

A validação contábil é executada após a geração do output estruturado pela LLM e utiliza exclusivamente os valores presentes no JSON retornado. Não há nova chamada ao modelo nessa etapa. Essa separação é importante porque mantém a interpretação semântica sob responsabilidade da LLM, mas transfere os cálculos e verificações de consistência para um procedimento determinístico, reproduzível e auditável.

A primeira verificação recai sobre campos cujo valor foi declarado como resultado da soma de contas de origem. Nesses casos, o sistema recalcula o total a partir das contas listadas no próprio output estruturado e compara o resultado com o valor informado pela LLM. Quando a diferença ultrapassa a tolerância definida, o valor validado passa a ser o valor recalculado, sem apagar o valor originalmente extraído. Desse modo, a análise preserva tanto a resposta do modelo quanto a correção numérica derivada das contas usadas como evidência.

A segunda verificação avalia a coerência patrimonial do balanço. Sempre que os campos necessários estão disponíveis, o método compara o total de ativos com a soma dos passivos e do patrimônio líquido, respeitando uma tolerância para arredondamentos. Quando todos os componentes estão presentes e a diferença permanece dentro da tolerância, o balanço é classificado como consistente nesse critério. Quando a diferença é material, o resultado é sinalizado como inconsistência. Quando faltam campos essenciais, o critério é marcado como não avaliável, evitando transformar ausência de informação em erro contábil.

Essa camada de validação não substitui o julgamento do analista, mas reduz a confiança cega na saída da LLM. Seu papel é destacar valores que podem ser aceitos automaticamente, valores que foram corrigidos por uma regra objetiva e pontos que exigem revisão humana antes de serem usados em análise financeira.

3.5 Comparação Analítica e Dashboard

Após a validação, os campos extraídos são organizados em uma tabela comparável e entregues ao analista em dashboard. Em uso normal, não se pressupõe a existência de um gabarito: o dashboard é o produto da extração e serve como base para análise financeira. Para este artigo, entretanto, foi utilizado um gabarito manual de uma empresa real anonimizada com valores de referência para os anos de 2023, 2024 e 2025.

O dashboard, neste contexto, não é a contribuição principal enquanto interface web; ele representa a forma final da análise entregue ao usuário. A comparação com gabarito é um procedimento experimental específico deste trabalho, usado para medir a aderência do output estruturado produzido pela pipeline. Seu papel é tornar visível a substituição da planilha manual: os campos extraídos pela LLM e validados pelas regras são apresentados em uma estrutura que permite inspeção rápida por analistas de fundos de investimento.

4 Experimentos e Resultados

A avaliação do projeto combina duas perspectivas. A primeira é uma validação técnica da etapa determinística, para verificar se as regras contábeis se comportam corretamente em cenários controlados. A segunda é uma avaliação aplicada da extração, na qual o dashboard gerado pela pipeline para a empresa anonimizada é comparado a um gabarito manual disponível para este artigo. Essa segunda perspectiva é a mais importante para o objetivo prático do trabalho, pois reproduz a situação em que um fundo de investimento deseja substituir uma análise manual por uma extração padronizada e verificável.

Na validação técnica, foram criados testes unitários e de integração para os principais cenários das regras. Os testes verificam balanços consistentes, balanços com diferença material, tolerância de arredondamento, campos obrigatórios ausentes, somas corretas, somas divergentes, valores não numéricos, ausência de contas

Tabela 1: Resumo da comparação entre dashboard gerado e gabarito da empresa anonimizada.

Categoria	Células	Participação
Coincidentes com o gabarito	57	82,6%
Divergentes	9	13,0%
Ausentes na extração	3	4,4%
Total avaliado	69	100,0%

Tabela 2: Consumo de tokens e custo estimado por balanço da empresa anonimizada.

Ano	Entrada	Saída	Cache	Custo USD	Custo BRL
2023	16.355	7.492	0	0,045980	0,239097
2024	24.285	7.070	14.080	0,040525	0,210729
2025	25.913	6.705	0	0,049607	0,257958
Total	66.553	21.267	14.080	0,136112	0,707784

de origem e filtragem por grupo contábil. Um teste de desempenho valida que uma extração estruturada com 30 campos analisados é processada em menos de três segundos após a saída da LLM estar disponível.

Na avaliação aplicada, foram considerados os anos de 2023, 2024 e 2025. A fonte de dados do dashboard foi identificada como a matriz de IA da aplicação, composta pela última extração estruturada de cada ano e, quando disponível, pelo respectivo snapshot validado pelas regras contábeis. Para cada campo, a análise considera: valor de referência, valor extraído e validado pela pipeline, diferença absoluta e status final. Valores monetários foram comparados após arredondamento para inteiro, reproduzindo a granularidade visual do dashboard; índices de liquidez foram comparados com uma casa decimal.

Os testes indicam que a camada determinística consegue detectar inconsistências que poderiam passar despercebidas em uma saída JSON formalmente válida. Em um cenário sintético, por exemplo, ativos de 1000, passivo circulante de 650, exigível de longo prazo igual a 0 e patrimônio líquido de 300 produzem diferença de 50, classificada como inconsistência de alta severidade. Em outro cenário, um campo informado como 690, mas sustentado por contas de origem que somam 700, é corrigido no resultado validado, mantendo 690 como valor original auditável.

Na comparação aplicada com a empresa anonimizada, foram avaliadas 69 células do dashboard, considerando campos monetários, campos em branco esperados e índices de liquidez nos anos de 2023, 2024 e 2025. Dessas células, 57 coincidiram com o gabarito, 9 apresentaram valor divergente e 3 ficaram ausentes na saída estruturada. A aderência global ao gabarito foi, portanto, de 82,6%. A Tabela 1 resume o resultado.

Além da acurácia por campo, foi avaliado o custo de processamento dos três balanços usados no experimento. A Tabela 2 apresenta os tokens registrados no metadata das extrações estruturadas efetivamente usadas pelo dashboard. O custo foi estimado com as tarifas da OpenAI para o modelo `gpt-5.4-mini`: US\$ 0,75 por milhão de tokens de entrada, US\$ 0,075 por milhão de tokens de entrada em cache, US\$ 4,50 por milhão de tokens de saída e câmbio de R\$ 5,20 por dólar. O processamento dos três documentos consumiu 66.553 tokens de entrada, 21.267 tokens de saída e 14.080 tokens em cache, totalizando custo estimado de US\$ 0,136112, ou R\$ 0,707784.

Esses valores indicam que o resultado satisfatório de aderência ao gabarito foi obtido com custo operacional baixo. Em uma rotina de fundos de investimento, esse aspecto é relevante porque a análise pode envolver múltiplas empresas e múltiplos períodos; portanto, o custo por documento precisa ser compatível com uso recorrente.

As divergências se concentraram em poucos campos, conforme a Tabela 3. Em 2025, a diferença de R\$ 4.990.321 em *Permanente* aparece compensada por diferença praticamente simétrica em *Realizável Longo Prazo*, indicando possível erro de classificação entre grupos do ativo não circulante. Em 2024, o maior erro absoluto ocorreu em *Contas a Receber* de curto prazo, com diferença de R\$ 28.162.426. O prazo médio de recebimentos não foi calculado para nenhum dos três anos, o que é coerente com a restrição metodológica de não inferir valores sem informação suficiente no documento.

Tabela 3: Campos divergentes ou ausentes na comparação com o gabarito.

Campo e ano	Dashboard	Gabarito	Diferença
Permanente, 2025	32.797.180	37.787.501	-4.990.321
Realizável Longo Prazo, 2025	105.053.852	100.063.532	4.990.320
Contas Receber Emp. Ligadas/Sócios, 2025	30.050.000	30.500.000	-450.000
Impostos a Recuperar/Diferidos, 2023	49.037.932	42.442.579	6.595.353
Contas a Receber, 2024	27.349.941	55.512.367	-28.162.426
Salários e Impostos, 2023	40.013.015	39.979.513	33.502
Salários e Impostos, 2025	50.457.924	50.341.450	116.474
Prazo médio de recebimentos, 2023	–	90	–
Prazo médio de recebimentos, 2024	–	103	–
Prazo médio de recebimentos, 2025	–	90	–
Liquidez Geral, 2024	1,1	1,0	0,1
Liquidez Geral, 2025	1,1	1,0	0,1

Os resultados sugerem que a pipeline conseguiu reproduzir a maior parte da análise manual para a empresa avaliada, especialmente nos totais principais, passivos, bancos, fornecedores, ativo circulante e indicadores de liquidez corrente e seca. Ao mesmo tempo, os erros observados mostram que a extração estruturada ainda precisa de revisão humana em campos sensíveis a classificação contábil e em indicadores que dependem de informações não explicitadas no balanço patrimonial.

5 Discussão

A abordagem implementada mostra que LLMs são úteis para lidar com a variabilidade semântica dos balanços, mas devem ser cercadas por mecanismos de controle. A etapa de output estruturado reduz a liberdade de formato do modelo e permite organizar os valores em uma estrutura comparável; a etapa de validação reduz a dependência de cálculos produzidos pela LLM; e a preservação do valor original permite reconstruir como cada valor validado foi obtido. No experimento deste artigo, essa estrutura comparável também permitiu medir a aderência do dashboard a um gabarito manual.

Uma decisão relevante foi preservar o JSON bruto e armazenar correções apenas em snapshots de validação. Isso evita que a resposta original do modelo seja apagada por uma etapa posterior e permite comparar extração, correção e evidência. Em aplicações financeiras, essa distinção é essencial: corrigir automaticamente um valor só é aceitável quando a regra é inequívoca e a origem do cálculo pode ser inspecionada.

Também se observou que a validação contábil depende da qualidade do schema. Quanto mais explícita for a estrutura exigida da LLM, mais fácil é validar a resposta. Por outro lado, schemas muito extensos podem aumentar custo, latência e risco de campos nulos ou ambíguos. O projeto adotou um conjunto de campos voltado à análise patrimonial e de liquidez, suficiente para o escopo da disciplina e extensível para novas demonstrações.

No contexto de fundos de investimento, a principal implicação prática é a mudança no papel do analista. Em vez de localizar manualmente cada valor no PDF e transcrevê-lo para uma planilha, o analista passa a revisar uma extração estruturada, observar alertas de validação e investigar apenas campos problemáticos. Essa mudança não elimina a revisão humana, mas reduz o esforço repetitivo e aumenta a rastreabilidade da análise.

As principais limitações estão ligadas à ausência de uma avaliação quantitativa sobre um conjunto grande e anotado de balanços reais. Os testes atuais demonstram comportamento esperado em cenários controlados, mas não medem acurácia por campo, erro relativo médio ou taxa de omissão em documentos variados. Outra limitação é que o OCR e a extração de tabelas ainda podem degradar a entrada enviada ao modelo. Se o parser perder a relação entre conta e valor, a LLM pode receber um texto já ambíguo. Por fim, a validação implementada cobre apenas somas de contas e a identidade patrimonial básica; índices de liquidez e outras relações contábeis aparecem no schema, mas podem ser ampliados em regras futuras.

6 Conclusão

Este trabalho apresentou um pipeline para extração estruturada e validação contábil de balanços patrimoniais em PDF com LLMs. A solução implementada combina leitura documental, saída JSON estruturada, preservação do resultado bruto, regras determinísticas e entrega dos valores em dashboard. Para validar o output estruturado, o dashboard de uma empresa real anonimizada foi comparado a um gabarito manual, alcançando 82,6% de aderência nas células avaliadas. O uso do modelo `gpt-5.4-mini` também mostrou que é possível obter resultado satisfatório com baixo custo estimado: os três balanços avaliados custaram aproximadamente R\$ 0,71 em chamadas de LLM. A principal conclusão é que a utilidade prática de LLMs em documentos financeiros não depende apenas da capacidade de gerar texto ou JSON, mas da integração com restrições de domínio verificáveis e métricas de comparação por campo.

Como próximos passos, recomenda-se construir um conjunto de avaliação com balanços reais anotados manualmente, medir acurácia por campo e erro numérico, comparar estratégias de prompt, testar modelos diferentes e ampliar as regras para índices de liquidez, subtotais adicionais, demonstração do resultado do exercício, balancetes e notas explicativas. Também é possível explorar uma segunda chamada controlada à LLM apenas para revisar campos inconsistentes, sempre mantendo a validação determinística como fonte de decisão numérica.

Agradecimentos

Este trabalho foi desenvolvido como projeto final da disciplina de Large Language Models do mestrado.

Referências

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.
- [2] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, 2020.
- [3] OpenAI. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2024.
- [4] Yiheng Xu, Minghao Li, Lei Cui, Shaohan Huang, Furu Wei, and Ming Zhou. Layoutlm: Pre-training of text and layout for document image understanding. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2020.
- [5] Pius Horn and Janis Keuper. Benchmarking pdf parsers on table extraction with llm-based semantic evaluation. *arXiv preprint arXiv:2603.18652*, 2026.
- [6] Sönke Tenckhoff, Mario Koddenbrock, and Erik Rodner. Llmstructbench: Benchmarking large language model structured data extraction. *arXiv preprint arXiv:2602.14743*, 2026.
- [7] Abhinav Kumar Singh, Harsha Vardhan Khurdula, Yoeven D. Khemlani, and Vineet Agarwal. The structured output benchmark: A multi-source benchmark for evaluating structured output quality in large language models. *arXiv preprint arXiv:2604.25359*, 2026.
- [8] Brandon T. Willard and Rémi Louf. Efficient guided generation for large language models. *arXiv preprint arXiv:2307.09702*, 2023.
- [9] Vikram Aggarwal, Jay Kulkarni, Aditi Mascarenhas, Aakriti Narang, Siddarth Raman, Ajay Shah, and Susan Thomas. Information extraction from fiscal documents using llms, 2025. ACM ICAIF Workshop.
- [10] Nelvin Tan, Zian Seng, Liang Zhang, Yu-Ching Shih, Dong Yang, and Amol Salunkhe. Improved llm agents for financial document question answering. *arXiv preprint arXiv:2506.08726*, 2025.

- [11] Siddhant Kulkarni and Yukta Kulkarni. Benchmarking multi-agent llm architectures for financial document processing: A comparative study of orchestration patterns, cost-accuracy tradeoffs and production scaling strategies. *arXiv preprint arXiv:2603.22651*, 2026.